

Ped-Agent 项目阶段总结

目标、功能、架构、创新点与剩余实验评估方案

正式证据库 → 可验证问答 → Flow Evidence → 场景诊断

本地优先 · 证据约束 · 可追溯 · 可重复

报告日期：2026-08-06

依据：本地 main 分支当前代码、研究资产和自动化验证结果

项目概览

Ped-Agent 已形成一个面向行人流研究的、本地优先且证据约束的研究智能体框架。当前工程主干已经成型，下一阶段重点不是继续堆叠功能，而是完成正式知识资产、真实数据集和真实模型调用的科学验收。

项目研究主线为：

正式证据库 → 可验证问答 → Flow Evidence → 场景诊断

当前状态可以概括为：

- 总体架构已经稳定：**项目统一划分为知识与证据底座、检测追踪与流动分析、LLM 问答与会话三个基础模块
- 工程能力基本成型：**证据问答链和视觉轨迹工作台已具备完整的软件流程
- 科研资产仍待建设：**正式 Catalog、Manifest、Gold Questions 和真实视觉任务仍为空
- 下一关键里程碑明确：**先完成正式证据库和检索验收，再进行真实问答、公开轨迹和场景诊断实验

项目目标与功能

总体目标

Ped-Agent 的目标不是成为通用聊天机器人，而是建立一条可追溯、可复查、可重复的行人流研究链。系统需要管理经过筛选的文献、法规和标准，从视频或轨迹中形成可计算证据，并通过受约束的 LLM 生成经过验证的研究回答。

三个基础模块

模块	核心职责	已具备功能	当前成熟度
知识与证据底座	管理系统能够信任、检索和引用的事实	质量规则、Manifest 预检、PDF 解析、Catalog/Vault、FTS5、Chroma、检索评测	工程基础完成，正式数据建设中
检测追踪与流动分析	将视频或轨迹转化为结构化行人流证据	视频上传、模型校验、检测跟踪、人工复核、标定、投影、后处理、指标分析和导出	工程闭环可用，真实数据待验收
LLM 问答与会话	调度证据并只展示经过验证的回答	会话、Run、SSE、混合检索、条件外搜、结构化生成、引用校验、语义复核、一次修订和持久化	工程闭环可用，正式语料与真实服务待验收

研究应用

应用	当前状态	说明
文献问答	工程可用、数据受阻	前后端和问答链已具备，但正式知识库当前为空
轨迹分析	工程可用、真数待验	视觉轨迹工作台已形成端到端流程
场景诊断	下一阶段	需要联合正式证据与 Flow Evidence
安全评估	后续	应保持为研究辅助，不直接输出合规结论
实验支持	后续	需要在知识底座和问答闭环完成验收后建设

视觉工作台当前流程为：

上传 → 预检 → 推理队列 → 检测跟踪 → 人工复核 → 标定 → 世界坐标投影 → 后处理 → 分析 → 渲染与导出

总体架构




图 1：Ped-Agent 当前三模块研究架构及研究应用关系。

项目创新点

以下创新点目前主要体现为架构和方法创新，仍需通过正式实验验证其有效性和相对优势。

- 1 **事实、计算和解释分层**：文献事实归知识底座，轨迹计算归分析模块，证据编排和解释归 LLM 模块，避免将原文、计算结果和模型结论混为同一事实层。

- 2 **治理型知识库**：文献必须依次经过候选发现、筛选、质量核验、合法全文确认、Manifest 和导入，并受 JCI、中科院分区、引用量、哈希和版本规则约束。
- 3 **先校验、再呈现**：每个事实 Claim 必须绑定 Citation，并由独立模型执行语义复核；二次失败时关闭回答，不展示未验证草稿。
- 4 **Flow Evidence 桥接机制**：轨迹分析结果携带场景、时间范围、算法版本、输入哈希和质量限制，使 LLM 能够引用可回查的计算证据。
- 5 **不可变产物与局部重算**：像素轨迹、复核轨迹、标定报告、世界坐标轨迹和分析结果分别版本化，修改标定时无需重新运行检测跟踪。
- 6 **标定质量门禁**：世界坐标检查点 RMSE 必须不超过 0.10 m，否则系统保留像素轨迹，但停止输出正式物理指标。
- 7 **隐私约束的可观测性**：LangSmith 默认关闭，启用后不上传证据正文、对话历史、未验证草稿和密钥，且观测服务故障不改变本地 Run 结果。

当前验证与资产状态

自动化验证

当前代码快照已经通过以下验证：

验证范围	结果
核心包测试	58 passed, 1 skipped
后端服务测试	59 passed
前端测试	15 passed
前端生产构建	成功
合计	132 passed, 1 skipped

这些结果证明工程接口、状态流转和模拟集成路径具备较好的回归基础，但不能替代真实科研数据、真实模型和真实服务的端到端验收。

研究资产

资产	当前数量或状态
候选文献	60 篇，全部为 unscreened
本地待治理 PDF	14 份
正式筛选记录	0
期刊指标核验记录	0
文献 Manifest	0
Gold Questions	0
Catalog 正式资源	0
Catalog 正式切块	0
真实视觉任务	0

主要缺口与风险

风险	影响	应对方式
正式知识库为空	文献问答无法形成真实证据闭环	优先完成筛选、质量核验和试点入库
真实服务尚未验证	无法确认 DeepSeek、Embedding、外搜和 LangSmith 的实际连通性	单独执行受控 Smoke Test 并保留脱敏报告
视觉模块仅通过模拟数据测试	无法证明检测、跟踪和物理量精度	先验证公开轨迹，再进行带人工真值的视频实验
Flow Evidence 尚未接入问答链	场景诊断不能形成完整跨模块闭环	建立版本化契约和只读检索接口
科研应用边界容易扩张	安全评估可能被误解为合规结论	保留代理指标、限制说明和人工审核门禁
前端 Plotly 分块较大	首次加载性能可能受到影响	使用按需加载和路由级代码分割

剩余实验与评估方案

阶段一：正式语料与检索验收

实验	核心任务	验收门槛
语料治理	依次完成筛选、指标核验、合法全文、Manifest 和批次导入	试点 20 篇文献；A 级不少于 8，A+B 不少于 18，例外不超过 2，高影响文献不少于 14
Gold Set	建立覆盖五类主题、法规、方法和无答案问题的 30 道问题	问题、预期资源和页码或条款定位均经过人工审核
检索对照	比较 FTS5、Chroma 和 Hybrid RRF，并进行切块与查询改写消融	Recall@5 $\geq$ 0.80，MRR $\geq$ 0.70，定位命中率 $\geq$ 0.75，非正式资料泄漏率 = 0

阶段二：真实问答闭环

执行 DeepSeek、Embedding、学术外搜和脱敏 LangSmith 的真实连通实验，并加入无证据、冲突证据、诱导提问和服务异常样本。

建议采用以下初始门槛：

- Claim 支持率不低于 95%
- 引用准确率不低于 95%
- 无证据幻觉率为 0
- 不受支持的事实比例不高于 2%
- 二次验证失败时未验证草稿展示率为 0

阶段三：轨迹和视觉算法验收

首先使用一个带真值的公开轨迹数据集，隔离检测误差，验证密度、速度、流量、OD、停留时间和基本图。轨迹指标通过后，再建立小规模人工标注的混合流视频集，评估行人、撑伞行人、自行车和电动车的检测跟踪能力。

指标类型	建议评估项	建议初始门槛
轨迹指标	速度 MAE、密度误差、流量误差、OD 准确率	速度 MAE ≤ 0.10 m/s；流量误差 $\leq 5\%$ ；OD 准确率 $\geq 90\%$
检测	各类别 Precision、Recall、F1、mAP	先建立人工基线，再冻结正式门槛
跟踪	HOTA、IDF1、ID Switch、轨迹完整率	不低于选定公开基线
接触点	脚点或轮胎接地点误差	同时报告像素误差和世界坐标误差
标定	独立检查点世界坐标 RMSE	≤ 0.10 m
重复性	同配置重复运行的结果哈希	确定性阶段必须一致

阶段四：Flow Evidence 与场景诊断

建立版本化 FlowEvidence 契约，将轨迹指标以只读方式接入问答链，并比较以下三种实验条件：

- 1 仅使用文献和法规证据
- 2 仅使用 Flow Evidence
- 3 联合使用正式证据和 Flow Evidence

验收要求包括：所有数值结论均能回查分析产物，所有规范性结论均引用正式来源，输入哈希、算法版本、单位、时间范围和限制字段完整率达到 100%，不受支持结论数量为 0。

阶段五：鲁棒性、隐私和可用性

通过故障注入测试索引过期、Embedding 不可用、外搜限流、SSE 断线、服务重启、LangSmith 故障、模型缺失、上传损坏和标定失败等场景。

核心验收标准为：

- 未验证草稿展示率为 0
- 敏感信息和证据正文外泄率为 0
- 终态 Run 不发生非法变化
- 模块降级状态能够明确展示
- SSE 重连不会重复或丢失终态事件
- 研究人员能够识别输出来源、限制和复查入口

推荐执行顺序




图 2：从正式语料建设到组合研究应用的推荐实验顺序。

资料发现、筛选、质量评价、全文确认、Manifest、导入和评测仍应作为独立阶段逐项确认，不应因为完成前一步就自动进入下一步。

实验可重复性要求

每次正式实验应冻结并记录以下内容：

- 数据集、文献库和 Manifest 版本
- 代码提交 SHA 与依赖锁文件
- 检测、跟踪、Embedding 和 LLM 模型标识
- Prompt、切块、检索和分析参数
- 输入文件哈希、标定版本和场景定义
- 原始指标、汇总指标、失败样本和人工复核结论
- 运行环境、耗时、Token、成本和硬件信息

任何改动只有在核心回归、模块验收和跨模块验收均通过后，才能升级为新的正式基线。

项目依据

- [Ped-Agent 三模块总体架构设计](#)
- [Ped-Agent 证据问答链](#)

- [Vision trajectory workbench](#)
 - [研究资料治理目录](#)
 - [试点评测配置](#)
 - [语料配额规则](#)
-

本报告用于当前阶段汇报和实验规划。工程能力、真实运行结果与科研有效性结论必须分别陈述。